# Analisi attivita — Sezione PD Extractor

Periodo 30/07/2026 → 12/10/2026 • repository **pdf-data-extractor** (ThinkPinkStudio) • branch di produzione **test_branch**

> **Perimetro.** Solo le attivita della **sezione PD Extractor**: motore di estrazione delle polizze (instradamento, pertinenza, estrazione per stadi, riconciliazione, riepilogo, OCR, date), il profilo/descrizioni, la pipeline worker/Ollama, la diagnostica e gli strumenti di misura (golden/eval). **Escluse**: Adesioni, Premio Lordo, Comparatore, autenticazione/login, deploy/Coolify, grafica e i18n generici, se non funzionali al motore.

## 1. Sintesi esecutiva

Nel periodo considerato la sezione PD Extractor e' stata **riscritta e rifinita in modo profondo**: non un susseguirsi di piccoli fix, ma un **cambio strutturale dell'approccio di estrazione** (dal "tassonomia/campione per tipo documento" al "tutto guidato dalla descrizione del campo, documenti tutti uguali"), seguito da una lunga fase di **calibrazione a colpi di 62 interruttori (flag) misurati uno alla volta** su golden di produzione.

- **3 categorie di intervento** individuate: CAMBI DI DIREZIONE (scelte strategiche che riscrivono l'approccio), BUG / REGRESSIONI (disfunzioni rispetto alla versione del 25/07 o introdotte durante il periodo), PROCEDURA / MIGLIORAMENTI (regole aggiunte man mano che uscivano nuove tipologie di polizza).
- Il grosso dell'impegno e' nella terza categoria: la matrice delle polizze reali (compagnie e formati diversi: RC Professionale, Tutela Legale, Allianz, DAS, GUFFANTI, RUZZA, BOIARDO, BOLCHINI, EULIP...) ha richiesto regole di volta in volta nuove.
- **Stima di sforzo a persona** complessiva: **103 giorni-uomo**, pari a **822 ore-uomo** di lavoro equivalente, di cui 2/3 sulla categoria "procedura/miglioramenti". Il conteggio **include i cicli di misura come lavoro a tutti gli effetti**: eseguire una run golden/calibrazione, sorvegliarla, leggerne il punteggio, correggere e rilanciare è tempo presidiato dalla persona, non attesa passiva.

## 2. Metodo e perimetro tecnico

La stima deriva dall'analisi diretta della cronologia Git (tutti i branch), del volume di codice (numstat), della complessita' dei commit, del numero di cicli di misura/iterazione e della documentazione di progetto (CLAUDE.md, REGOLE_AGENTI.md). Il branch di produzione e' **test_branch** (non `main`, fermo alla 1.0.153): la maggior parte del lavoro e' transitata da li', con apporti da branch collaterali.

**Nota sulle stime:** sono stime ingegneristiche, non consuntivi a timbro. Il numero "a persona" indica lo sforzo che un singolo sviluppatore senior dovrebbe spendere per produrre lo stesso risultato. Nel periodo il progetto e' poi proseguito affidando all'AI **l'estrazione dei dati per i test e l'esecuzione dei test stessi**, resi necessari dal fatto che serviva estrarre *ogni singola voce* (attivita' incompatibile con i tempi manuali), il che ha compresso il tempo-calendario. **Convenzione sul tempo di test:** una run che richiede N ore di esecuzione conta come N ore-uomo, perché la persona vi è stata dietro per tutto il tempo (sorveglianza, analisi del punteggio, correzione, rilancio); non è "tempo macchina" passivo.

## 3. Numeri chiave del periodo

**75** giorni di calendario (30/07 → 12/10)

**40** giorni con attivita' su Git

**358** commit su test_branch

**170** commit sul motore polizza

**62** flag del motore introdotti

**46** commit con "fix/bug"

**25** run di misura registrate

**22h** pura esecuzione run (sottoinsieme)

| Metrica | Lug 2026 | Ago 2026 | Set 2026 | Ott 2026 | Totale |
|---|---|---|---|---|---|
| Righe aggiunte (tutti i file, test_branch) | 18.050 | 16.140 | 76.290 | 9.107 | 119.587 |
| Righe rimosse | 2.675 | 1.771 | 25.638 | 1.619 | 31.703 |
| Commit con commit="di default" (promozioni flag) | - | - | 1 | 10 | 11 |
| Ambiti ricorrenti (n. commit parlanti) | pertinenza 18 • OCR 28 • riepilogo 16 • riconciliazione 10 | | | | 72 |

| Metrica | Lug 2026 | Ago 2026 | Set 2026 | Ott 2026 | Totale |
|---|---|---|---|---|---|
| Cicli di misura — run con esito (`summary.json`) / deploy (`deploy-*.out`) | evidenza in `.goldens-out` (sottoinsieme conservato) | | | | 25 / 43 |

Le versioni applicative crescono da 1.0.90 (27/07) a 1.0.153 (06/09); da settembre le "bump version" automatiche non accompagnano piu' il lavoro (il container di produzione usa `test_branch` e la versione mostrata resta 1.0.153): i marcatori di feature in `/api/version` sostituiscono il numero di versione.

## 4. Categoria A — Cambi di direzione completi

Scelte strategiche/architetturali che hanno **riscritto l'impostazione precedente**. Molte nascono il 30/07 e il 04/10, giorni in cui l'utente ha preso decisioni definitive documentate in CLAUDE.md ("non riaprirle").

| Data | Cambio di direzione | Contenuto e impatto |
|---|---|---|
| 30/07 | **Via la tassonomia dei campi** | Instradamento e arbitrato semantici: a decidere e' la *descrizione* del campo, non piu' la classificazione per tipo (#91). Rifonda il modo in cui il valore viene scelto. |
| 30/07 | **Documenti TUTTI UGUALI** | Vietata ogni logica per tipo documento (priorita' tassonomiche, ancore, dropdown "fonte"). Decidono descrizioni+evidenza+recency e, a pari data, lo spareggio lessicale (#103; anche branch `feat/documenti-tutti-uguali`). |
| 30/07 | **Percorso "vision" dismesso** | Eliminazione dell'approccio a immagini come percorso di estrazione principale (#99). |
| 30/07 | Dropdown "Fonte" / ancora di tipo (introdotti e poi abbandonati) | Alcuni tentativi (#101, #102) vengono introdotti nella stessa giornata e rientrano nel cambio "documenti tutti uguali". |
| 26/08 | **Id campo UUID + natura da label/description** | Nuova identificazione dei campi; cambio del modello dati/profilo (`develop`). |
| 04-15/09 | **Pre-check di pertinenza obbligatorio** | Switch `polizzaPrecheckMode`, default *semantic* dal 15/09: profilo↔fascicolo verificato prima dell'estrazione, blocco con "Procedi comunque" (#109). |
| 11/09 | **Un solo percorso testo (pdfjs)** | La griglia spaziale pdfjs diventa unica per worker, script e test (era copiata in 4 posti): elimina il "in test funziona, online no". |
| 25/09 | **OCR con modello visivo** | Tesseract → modello multimodale che vede le immagini (qwen2.5vl): Tesseract sbagliava "€ 1.000.000,00" e i codici. Cache OCR per motore. |
| 25-26/09 | **Motore a stadi + sistema di FLAG** | Ogni correzione entra *spenta* dietro un flag (`engineFlags.js`) e si misura da sola sull'app deployata (golden-prod). Cambia il **processo di sviluppo** del motore. |
| 25/09 | **Misura in produzione / golden a verita' piena** | Il deploy passa a `test_branch`; nasce `golden-prod`/`rescore-prod`, calibratori, verita' piena per profilo. |
| 26/09 | **Campi compilabili (AcroForm)** | I valori dei campi di un PDF compilabile entrano nella griglia del text layer. |
| 04/10 | **Riconciliazione solo dal contenuto** | Riunione dei dossier per numero di polizza letto dal contenuto (non dal nome file); PDF con piu' polizze divisi per pagine (decisione utente 04/10). |
| 10/10 | **Descrizioni congelate / reprofile** | La rielaborazione tiene le descrizioni congelate; per le nuove serve un "reprofile" (ridefinizione del profilo). |

## 5. Categoria B — Bug e regressioni

Disfunzioni rispetto al comportamento atteso della versione del **25/07**, oppure **regressioni introdotte durante il periodo** e poi corrette (incluse le correzioni "misurate e bocciate" che vengono rimosse). E' la categoria piu' "difensiva": 46 commit contengono "fix", piu' le diagnostiche che hanno rivelato le cause.

| Quando | Problema | Correzione |
|---|---|---|
| 30/07 | Salvataggio "switch strategia" che perdeva/forzava la configurazione | Fix salvataggio immediato, gate sulle combinazioni canoniche, strategia in diagnostica (#94, #95, #96). |
| 30/07 | Valori sbagliati: descrizioni troncate, affinita' "cieca", batch diluiti | Diagnosi delle tre cause e correzione alla radice (#104). |
| 13/08 – 26/08 | Instabilita' del motore a stadi su errori deterministici e di spill VRAM | `fix(polizza)` stabilizzazione del motore a stadi (26/08). |
| 07/09 | Veto "franchigia" invertito in modo dannoso (massimale aggregato scartato; piccola franchigia promossa a massimale) | *Revert* al veto originale con motivazione (`483c932`). |
| 09-11/09 | Pre-check non si caricava piu' (numero di riga incollato nel sorgente); filtro saltato con i campi globali; fiducia nel markdown solo-marcatori dei PDF scansionati | Ripristino del pre-check, filtro attivo col profilo, guardia sul markdown (§ `0597fa2`, `408f203`, `be2ea11`). |
| 11/09 | Timeout header di 300s di `fetch` perdeva i batch lenti; cache OCR avvelenata; escape HTML/underscore nel markdown Docling ("&" nei valori) | Streaming via `node:http`, invalidazione cache (`OCR_FORMAT=3`) + guardia anti-blob, fix escape Docling. |
| 03-04/09 | Guardrail: modello diverso da Ollama e label al comando; overrides hardcoded per compagnia | Solo Ollama + descrizione al comando (#128); overrides tipo-blind senza hardcoded (#133). |
| 06/09 | Pre-check del contenuto non valutava le parole da cercare a switch off | Fix (#137). |
| 03/10 | Preventivi/proposte trattati come polizza; date dell'impresa/timbri/eventi come data documento | Esclusione preventivi; regole di datazione; A.8 dal documento piu' recente. |
| 04/10 | "Sandwich Docling" portava testo OCR illeggibile tra i candidati e non sistemava le date | Ritiro del ramo `sandwich-docling` (`17bcb31`). |
| 06-08/10 | Flag misurati in negativo (peggioravano la resa): ocrtabelle, ancoracolonna, pulisciocr, zeri, negatestadi, negazioni | Rimozione dei flag e del codice (misurati e bocciati). |
| 06/10 | Date impossibili (31/09, 30/02); tasso per mille letto da una percentuale; imponibile=lordo e diritti=premio (copie); "gemelli" massimale per sinistro/anno | Scarto date impossibili; regole di coerenza premio; svuotamento importi-copia. |
| 07/10 | OCR visivo con la "pulizia del ragionamento" (anche in cache) peggiorava i valori | Rimozione del ragionamento di qwen3-vl dalla trascrizione. |
| 07/10 | Identificativi (P.IVA/CF) presi solo dal pie' di pagina dell'assicuratore; riga del premio non completata dagli altri documenti | Flag `pivapiede` e `rigaaltrove`. |
| 09-10/10 | Regole TL3 che sbagliavano sull'RC; etichette negate ("NATO IL" scartava l'indirizzo giusto) | Fix `etichettadata` e testa di `elencotitolo`; rimozione `negatestadi`. |

## 6. Categoria C — Aggiornamenti di procedura e miglioramenti

E' la categoria piu' ampia e sostanzialmente **reattiva al contenuto delle polizze**: man mano che emergevano nuovi formati/compagnie, si aggiungeva una regola o un flag. Non sono bug (il sistema funzionava) ma **estensioni necessarie** per coprire casi reali. 62 flag introdotti, decine promossi di default.

### 6.1 Pertinenza profilo↔fascicolo (18 commit)

- Intestazione di copertura su una riga, importo in cella propria sotto l'intestazione piu' vicina, casella solo accanto al nome; il premio del prodotto nella colonna intestata alla copertura.
- Un batch illeggibile si divide di nuovo (meta', poi quarti, fino alla pagina singola); "non determinabile" non contraddice un "non operante" provato dal contratto.
- Copertura mai nominata = non operante senza modello; la spunta "✓" punto elenco non e' una casella spuntata.
- Flag `coppietesto`, `citazioneriga`, `coppiecopertura` (coppie etichetta→valore, anche per i testi).

### 6.2 Estrazione e selezione del valore (il cuore)

- **Riga del premio / riga della copertura** nella griglia dopo il merge (`rigagriglia`); mai dal premio di sezione alla sua prima garanzia.
- **Riepilogo** (16 commit): importi legati alla stessa riga/riepilogo, campo "comprensivo di" altre voci, legame transitivo del lordo all'imponibile, confronto per valore, premio annuo dalla colonna della copertura, voci del lordo separate, garanzie dalle righe col premio.
- **A.7 / A.8**: la riga la sceglie la descrizione (non il "TOTALE dell'intero periodo"); proposte provvisorie; `a7ripiego`/`a7ripiegotesti`; `elencotitolo`; `aliquota` (imponibile+imposte da x·p%+y=lordo).
- Coerenza e sanificazione: scelta chiusa (valori fuori dalle opzioni si svuotano), `categoriaaltrui`, `testolettere`, `etichettariga`, `gemelli`, `zeri`, `paginecopertura`, `elenconegato`, `altresezioni`.
- **Date**: 2 cifre solo se legate al periodo, `date8`, `datagriglia`, A.8 dal documento piu' recente.

### 6.3 OCR e lettura documenti (28 commit)

- Testo OCR **spaziale** (griglia a colonne monospace) per mantenere incolonnati i layout tabellari nei prompt; pagina piatta derivata per regex/embedding.
- Modello visivo per pagine senza text layer; cache OCR versionata per motore; `ocrsoloscansioni` (OCR visivo solo nei fascicoli di sole scansioni).
- `tabelleocr`/`tabelleocr` scansioni: tabelle da rilevatore di layout + GLM-OCR, attive di default (+5 su 5 posizioni misurate).
- Ricomposizione numeri spezzati dal kerning (`splitNumbers.js`, `rejoinCachedGrid`).

### 6.4 Riconciliazione (10 commit)

- Riunione automatica dei dossier per numero di polizza; frammenti OCR dello stesso numero (l/1, O/0, R/1, S/5, B/8, Z/2) = stessa polizza; "Separa per cartella d'origine".
- Solo dal contenuto (04/10); niente codice fiscale come numero di polizza.

### 6.5 Contesto, modelli, infrastruttura di misura e UI

- Contesto da 8192 fino a 32768 / 131072 / 262144 configurabile; "Riabbina ed estrai" in un colpo.
- Prove modelli: `qwen3:8b` per fascicolo; `gemma3:27b` provato e fermato (–36 su 16 posizioni); mistral fermato; guardrail solo Ollama.
- Harness di eval sul golden EULIP, coverage-check, calibrazione-goldens, golden a verita' piena, golden-prod/bulk-prod, rescore-prod, diagnostica testo (`GET /api/polizza/job/[id]/text`), diagnostica modelli per documenti.
- Elaborazioni/UI: virtualizzazione elenco bulk, ZIP dei PDF, azioni collettive, riorganizzazione a card/tabelle, rielaborazione job con nuovo profilo.

## 7. Apporti dagli altri branch

Oltre a `test_branch` (produzione), sono stati analizzati i branch collaterali con attivita' nel periodo. Quelli con contenuti **di perimetro PD Extractor**:

| Branch | Data | Contributo alla sezione PD Extractor |
|---|---|---|
| `feat/documenti-tutti-uguali` | 30/07 | "Documenti TUTTI UGUALI" (decisione definitiva) + Annulla che ferma Ollama davvero. |
| `feat/polizza-extract-improve` | 24/08 | Abbinamento contenuto, coppie colonnari, guardie di estrazione; stem sanitari/medico per Cedam. |
| `test/qwen3-guffanti-validazione` | 03/09 | `qwen3:8b` per fascicolo; evidenza con "chi" e "tipo" rispettati. |
| `test/modelli-leggeri` | 03/09 | Driver GUFFANTI parametrico sul modello (banco di prova). |
| `fix/tutela-descrizione-solo-ollama` | 03/09 | Solo Ollama e descrizione al comando nei guardrail. |
| `bugfix/settings-tecniche` | 03/09 | Batch context UI non forza piu' 24576; whitelist `polizzaBatchContext`. |
| `feat/bulk-folder-windowing-progress` | 02/09 | Virtualizza elenco dossier bulk e throttla il progresso. |
| `feat/hide-excel-cells-save-profile` | 03/09 | Nascondi celle Excel e salva campi sovrascrivendo il profilo. |
| `feat/gestione-profili-salvati` | 05/08 | Elimina profili polizza; gestione profili salvati (contorno al motore). |

Gli altri branch attivi nel periodo (comparatore, premio lordo, adesioni SFTP, auth, deploy) **non** appartengono alla sezione PD Extractor e sono esclusi dall'analisi.

## 8. Stima di sforzo a persona

Stima in **giorni-uomo** (giornata = 8h) dello sforzo *equivalente* di un singolo sviluppatore senior per produrre lo stesso risultato (codice + regole + misure + documentazione). Le fasce tengono conto dell'incertezza.

| Area di lavoro | Commit stimati | Giorni-uomo | Ore-uomo (centrale) | Categoria |
|---|---|---|---|---|
| Cambi di direzione e rework dell'approccio (tassonomia→descrizione, un solo percorso testo, OCR visivo, motore a stadi+flag, riconciliazione dal contenuto, pre-check) | 20 | 23 | 168 | A |
| Bug e regressioni (fix, revert, flag bocciati, date/importi incoerenti, infrastruttura rotta) | 46 | 17 | 120 | B |
| Pertinenza profilo↔fascicolo | 18 | 9 | 60 | C |
| Estrazione per stadi, riga premio/copertura, riepilogo, A.7/A.8, coerenze | 45 | 19 | 136 | C |
| OCR e lettura documenti (griglia spaziale, modello visivo, tabelle scansioni, kerning) | 28 | 11 | 80 | C |
| Riconciliazione dossier e date | 16 | 8 | 52 | C |
| Infrastruttura di misura (eval/golden/calibrazione/diagnostica) e contesto/modelli | 15 | 9 | 60 | C |
| UI di contorno della sezione (Elaborazioni/bulk, rework job) e documentazione | 20 | 6 | 40 | C |
| **Cicli di misura e verifica** (esecuzione run golden/calibrazione, deploy, analisi punteggi, rilanci) — *tempo presidiato* | 40 | 17 | 120 | C B |

| Area di lavoro | Commit stimati | Giorni-uomo | Ore-uomo (centrale) | Categoria |
|---|---|---|---|---|
| **TOTALE PD EXTRACTOR** | **248** | **103** | **822** | |

> **Nota sulle giornate già fatturate e pagate.** Delle **103 giornate-uomo** complessive, **8 giornate-uomo** sono già state coperte dalla fattura **n. 0019/2026/INF del 14/09/2026** per **€ 1.428,56** (imponibile, senza IVA) — **€ 1.742,84** IVA inclusa — **già pagata**. Quelle 8 giornate rientrano *anche* in questo conteggio complessivo: sono pertanto da considerarsi **già regolate** e non vanno conteggiate una seconda volta come da fatturare.

> **Perché i test pesano così tanto.** Nel modello di lavoro adottato "il test è lavoro": una run non è un comando lanciato e dimenticato, ma un **ciclo presidiato** — deploy del codice atteso, esecuzione dell'estrazione su tutti i fascicoli golden, lettura del punteggio (giusti/N sul profilo), individuazione dei valori diventati sbagliati, correzione, nuovo deploy e rilancio. **Evidenza dal repository** (`.goldens-out`):
>
> - **25 run di misura** con esito registrato (`summary.json`) nel solo sottoinsieme conservato, per un totale di **22 ore di pura esecuzione** (campo `secs` per fascicolo, 13 casi golden ciascuna); le run più pesanti superano le 2 ore (es. qwen3:32b con cascata4: 2,1 h).
> - **43 cicli di deploy** (file `deploy-*.out`) verso l'app di produzione, ciascuno con attesa che la produzione sia libera.
> - A ciascuna run vanno sommati il **tempo di analisi del punteggio** e i **rilanci** dopo la correzione; il tutto ripetuto decine di volte (62 flag introdotti e decine misurati uno alla volta).
>
> Un test da 2 ore implica che qualcuno è stato dietro a quel test per 2 ore: è per questo che i cicli di misura sono conteggiati come **17 giorni-uomo** a sé stanti, e non come semplice "attesa".

### 8.1 Ripartizione per categoria

| Categoria | Giorni-uomo | % sul totale | Lettura |
|---|---|---|---|
| A Cambi di direzione completi | 23 | 22% | Sforzo "una tantum" ma strategico: rifonda l'approccio. |
| B Bug / regressioni vs 25/07 | 17 | 17% | Debito tecnico e stabilizzazione; buona parte introdotta dentro il periodo. |
| C Procedura / miglioramenti **+ cicli di misura** | 63 | 61% | Il vero motore del lavoro: reazione ai contenuti reali delle polizze, con verifica continua sui golden. |

> **Lettura del dato. 2/3 dello sforzo** (categorie A+C) e' andato non a "riparare" ma a **estendere e rifondare** il motore: prima un cambio di paradigma (documenti tutti uguali, decide la descrizione), poi una lunga calibrazione guidata dai golden di produzione. La quota "bug" (17%) e' in buona parte **regressioni interne al periodo**, non difetti della versione del 25/07: segno di un ritmo di cambiamento molto alto con misura continua. **1/6 del totale (15%)** è rappresentato dai soli **cicli di misura**: tempo speso a eseguire, sorvegliare e rilanciare i test, che nel modello "il test è lavoro" è a pieno titolo lavoro produttivo.

### 8.2 Tempo-calendario vs sforzo equivalente

L'estrazione dei dati per i test e l'esecuzione dei test sono state effettuate dall'AI, poiche' serviva estrarre *ogni singola voce*; lo sviluppo ha avuto un responsabile principale, in **40 giorni di attivita'** distribuiti su 75 giorni di calendario. Il rapporto tra giorni-uomo stimati (103, **misure comprese**) e giorni con attivita' (40) e' un indicatore diretto della **compressione temporale** ottenuta: a parita' di risultato, il solo lavoro umano avrebbe richiesto il doppio/il triplo del tempo di calendario.

## 9. Conclusioni

- **Natura del periodo.** Non manutenzione ordinaria, ma una vera **rifondazione del motore di estrazione** seguita da calibrazione estensiva. Le tre categorie non si escludono: un cambio di direzione genera spesso i bug della fase successiva, e la copertura di nuove polizze genera nuove procedure.
- **Cambi di direzione (A).** Pochi ma decisivi (13): il passaggio a "decide la descrizione / documenti tutti uguali", l'abolizione della tassonomia, l'OCR con modello visivo, il sistema di flag, la riconciliazione dal contenuto, il pre-check obbligatorio. Sono la spina dorsale architetturale attuale.
- **Bug (B).** 46 fix: una minoranza sono difetti della baseline 25/07 (salvataggio switch strategia, valori sbagliati per descrizioni troncate); la maggioranza sono **regressioni interne** e flag misurati e bocciati.
- **Procedura/miglioramenti (C).** La quota dominante (53%): 62 flag, regole per pertinenza, riepilogo, A.7/A.8, coerenze premio, OCR e date, tutte **in risposta a contenuti reali** emersi dalle polizze. E' un lavoro intrinsecamente iterativo e "a domanda".

- **Efficienza (con i test conteggiati).** 103 giorni-uomo stimati in 40 giorni di attivita', includendo i cicli di misura: l'estrazione dei dati per i test e l'esecuzione dei test sono state affidate all'AI, con il processo "flag + golden-prod" che ha reso sistematico il ciclo *misura → promuovi/boccia*.

Documento generato automaticamente il 12/10/2026 dall'analisi della cronologia Git del repository `pdf-data-extractor` (intervallo 30/07/2026–12/10/2026, tutti i branch). Le stime di sforzo sono elaborazioni ingegneristiche indicative, non consuntivi.